RESUMO EXECUTIVO

O consumo se concentra na reverificação de sugestões.

A maior urgência operacional é o ciclo de falhas repetidas por falta de saldo e de chave. Ele impede processamento e torna os dias sem tokens uma leitura enganosa de economia.

HOJE

17,37 mi

17.366.507 tokens

2.258 chamadas

US$ 4,69

estimativa do fornecedor

7 DIAS

92,28 mi

92.279.454 tokens

11.768 chamadas

US$ 27,22

estimativa do fornecedor

15 DIAS

268,67 mi

268.670.847 tokens

33.065 chamadas

US$ 104,90

estimativa do fornecedor

Onde atuar primeiro

0. Restabelecer operação e conter falhas repetidas

352.508 falhas em 15 dias, incluindo 129.741 por saldo do provedor esgotado e 222.757 por chave local ausente. Entre 10 e 12/10, foram 124.280 falhas e zero tokens registrados.

1. Reduzir o contexto e a frequência do verificador

O verificador consome 64,7% dos tokens dos 15 dias. Reavaliações após a primeira verificação do dia somam 111,95 milhões de tokens. São concentrações de consumo; não são economia automaticamente disponível.

2. Revisar o custo da análise de risco

Risco responde por 5,8% dos tokens, mas 32,0% do custo estimado em 15 dias. O piloto deve medir qualidade e custo por oportunidade, incluindo recuperações.

Como ler: hoje é parcial até 11h; 7 dias = 07 a 13/10; 15 dias = 29/09 a 13/10. As janelas se sobrepõem e não devem ser somadas. Valores em USD são estimativas por tarifa, sem conciliação com fatura. Duas transcrições sem contadores têm custo desconhecido.

EVOLUÇÃO DIÁRIA

Zero tokens não significa operação saudável.

Os dias 10, 11 e 12/10 não tiveram consumo registrado, mas acumularam 124.280 tentativas falhas do crm-ai. Hoje contém somente as primeiras 11 horas.

BARRAS: TOKENS (escala 45 mi)

LINHA: FALHAS (escala 60 mil)

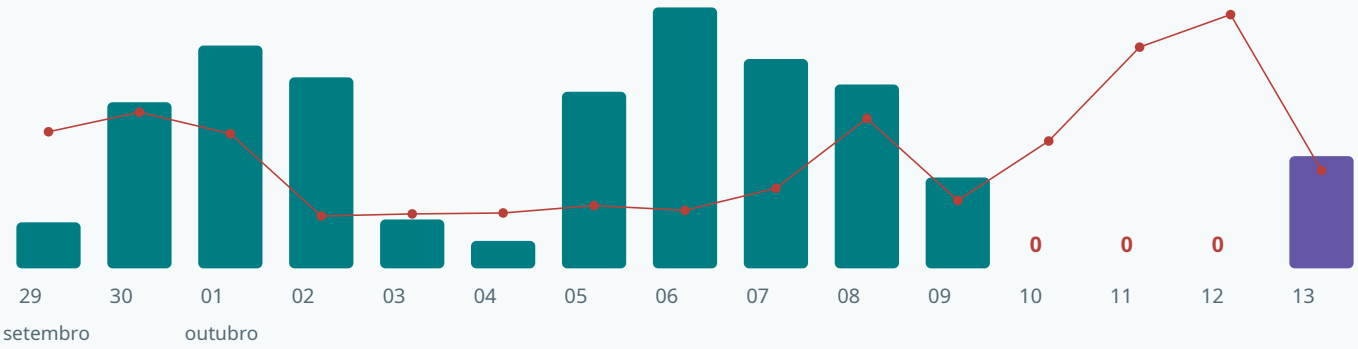

Dia	Chamadas	Tokens (mi)	USD est.	Falhas crm-ai
29/09	1.535	7,12	5,41	28.184
30/09	3.539	25,71	8,13	32.219
01/10	3.512	34,48	13,74	27.776
02/10	3.085	29,56	14,79	10.800
03/10	993	7,57	2,90	11.232
04/10	523	4,25	2,34	11.425
05/10	3.313	27,33	14,89	12.953
06/10	4.797	40,38	15,48	11.973
07/10	3.984	32,40	8,93	16.527
08/10	3.818	28,45	9,15	30.933
09/10	1.708	14,06	4,44	14.005
10/10	0	0,00	0,00	26.272
11/10	0	0,00	0,00	45.645
12/10	0	0,00	0,00	52.363
13/10*	2.258	17,37	4,69	20.201

* 13/10 parcial até 11h. Chamadas incluem todos os eventos registrados; falhas vêm dos logs de invocação do crm-ai, portanto têm cobertura diferente.

RANKING DE AGENTES

Volume de tokens e custo contam histórias diferentes.

O verificador domina o volume. A análise de risco, usando principalmente Terra, tem peso monetário bem maior que sua participação em tokens.

Agente	Hoje mi	7d mi	15d mi	USD 15d
Verificador de sugestões	10,99	60,14	173,82	37,75
Análise WhatsApp	3,78	22,35	58,21	20,88
Análise de risco	0,16	1,65	15,60	33,61
Análise Instagram	2,21	6,96	15,44	2,58
Checkout diário	0,15	0,56	2,54	5,90
Skopos Coach	0,00	0,18	0,68	1,90
Transcrição WhatsApp	0,04	0,15	0,62	1,42
Outras operações	0,04	0,30	1,76	0,84

Participação em 15 dias

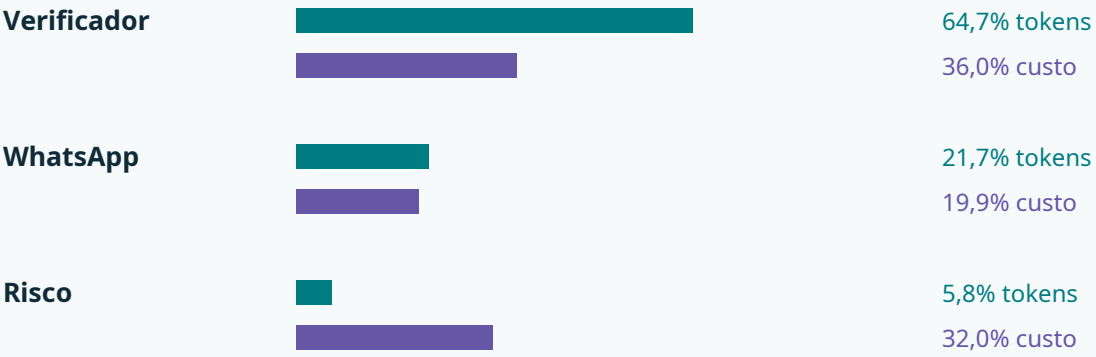

Modelo Terra: 20,68 milhões de tokens (7,7% do total), mas US$ 46,50 (44,3% do custo). Luna soma 247,32 milhões de tokens e US$ 56,69. Uma troca de modelo exige avaliação de qualidade; a tarifa não basta para definir o modelo adequado.

Os 15 dias misturam versões e configurações. A comparação não demonstra causalidade nem economia futura. Metas devem usar tokens e USD por execução comercial equivalente, incluindo a segunda passagem.

RANKING DE EMPRESAS

Staff e AVEP concentram 74,1% dos tokens em 15 dias.

O perfil de agentes e modelos afeta o custo: AVEP consumiu menos tokens que Staff, porém teve maior custo estimado no período de 15 dias.

Empresa	Hoje mi	7d mi	15d mi	USD 15d
Staff M&B	7,90	51,64	114,38	40,85
AVEP	4,44	18,79	84,70	44,13
Wagner Brum	1,51	6,44	20,95	4,83
Lumyne	1,13	5,52	16,80	6,23
Multiplix	2,21	6,96	15,47	2,81
Vetor Modular	0,07	2,26	13,87	5,51
Dominus	0,04	0,22	1,56	0,17
TRIASA	0,07	0,45	0,94	0,37

Distribuição dos tokens - 15 dias

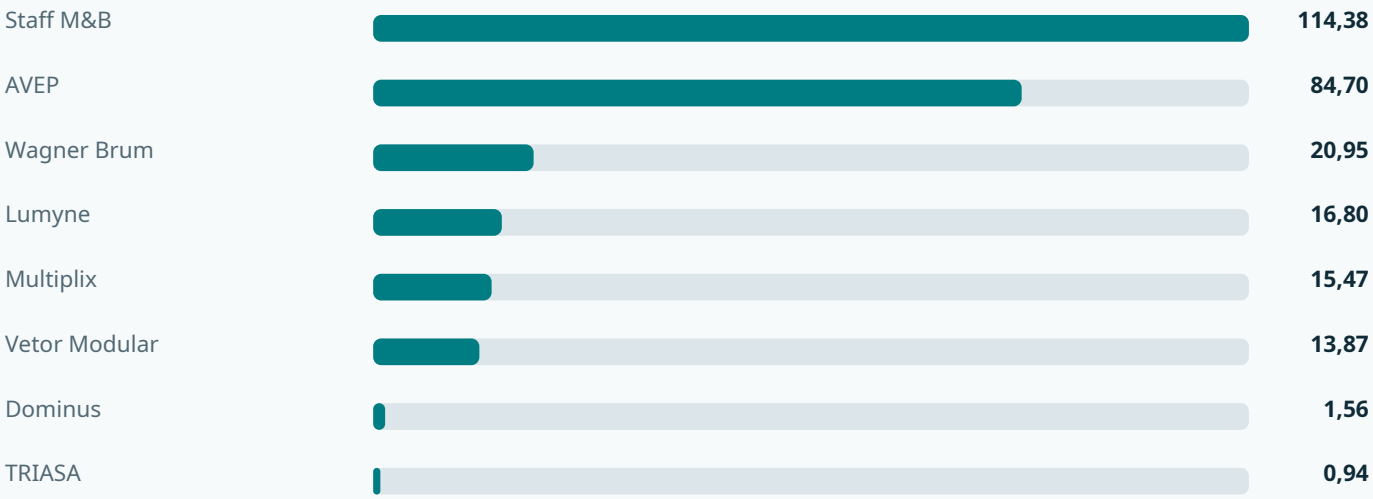

Priorizar pelo consumo e pelo tipo de carga: Staff representa 42,6% dos tokens; AVEP, 31,5%. Nos 7 dias, juntas somam 76,3%. A investigação do verificador deve começar nessas duas empresas e medir contexto, número de novas interações e recuperações.

Volumes menores não eliminam gargalos locais. O relatório de falhas deve acompanhar todas as empresas, mesmo aquelas sem tokens no período. Saldos e contratos atuais são grandezas separadas dos custos históricos.

VERIFICADOR DE SUGESTÕES

Reavaliação frequente e contexto grande dominam.

O ranking abaixo divide o consumo do verificador sem dupla contagem. Os recortes por tamanho, conteúdo e resultado são outras visões das mesmas chamadas.

Situação	Hoje mi	7d mi	15d mi
Primeira do dia	2,98	16,28	53,07
Reavaliação no dia	6,88	38,06	111,95
Recuperação completa	1,13	5,80	8,80

"Primeira do dia" não é primeira da vida da sugestão. Reavaliar a mesma sugestão não comprova repetição inútil: evidências podem ter mudado. Hoje não houve pedido integralmente idêntico repetido; em 15 dias foram 1.868 repetições idênticas.

Tamanho de evidência - 7 dias

Evidências	Chamadas	Tokens (mi)	% verificador
0-10	1.455	2,51	4,2%
11-40	997	4,46	7,4%
41-80	589	7,26	12,1%
81-119	498	8,39	14,0%
120 (limite)	2.170	37,51	62,4%

Contextos com mais de 80 evidências: 76,3% dos tokens do verificador nos 7 dias. Nas chamadas compactas, atividades **agent-skopos** ocupam 62,5% dos caracteres das evidências; WhatsApp ocupa 35,1%. Caracteres são diagnóstico textual, não atribuição exata de tokens.

Recuperação precisa de qualidade: nos 7 dias, 386 duplas compacta + completa usaram 10,78 milhões de tokens; 197 mudaram o resultado. Hoje, 37 de 68 duplas mudaram. A associação é temporal: mesma sugestão/empresa/modelo, chamada anterior em menos de 2 minutos. Isso não comprova qual resposta está correta. Preservar recuperação e medir economia líquida por sugestão.

FALHAS E CONTEXTO WHATSAPP

As falhas repetidas são a prioridade operacional 0.

Os erros abaixo são tentativas registradas pelo crm-ai. Falhas sem contadores não receberam tokens fictícios; ainda assim consomem capacidade de worker, banco e filas.

Causa	Hoje	7 dias	15 dias
Chave local ausente	6.098	81.208	222.757
Saldo provedor esgotado	14.096	124.730	129.741
Outras não classificadas	7	8	9
Servidor sobrecarregado	0	0	1
Total de falhas	20.201	205.946	352.508

Ação: validar resolução de credenciais, disponibilidade e saldo do provedor; aplicar espera progressiva e circuito por empresa/provedor/agente; retomar backlog com vazão controlada. Falhas deste grupo não demonstram cobrança de tokens: não confundir crédito SaaS com saldo do fornecedor.

WhatsApp: contexto fixo supera o trecho novo

Componente do input	Caracteres (mi)	% do input
Scorecard	15,79	48,9%
Contexto adicional	5,34	16,5%
Sugestões existentes	3,49	10,8%
Trecho novo	1,22	3,8%

Duplicação exata confirmada: em todas as 2.782 chamadas WhatsApp dos 7 dias, **additionalContext** também aparece nas instruções. São 5,23 milhões de caracteres repetidos. Nos 15 dias: 6.263 chamadas e 8,82 milhões de caracteres. Preservar uma cópia e medir redução real com tarifa/cache.

As proporções textuais não incluem tudo que o provedor tokeniza. Compactar scorecard e deduplicação exige preservar critérios e estado; o diagnóstico não justifica desativar a avaliação.

PLANO DE AÇÃO

Implementar por prioridade, medir por execução útil.

Os números identificam alvos. A economia líquida depende de publicação, qualidade das decisões, novas interações reais e volume processado.

PRIORIDADE 0

Estabilizar credenciais, saldo e repetição de erros

Confirmar configuração por empresa/provedor e distinguir saldo OpenAI de créditos SaaS. Limitar reintentos persistentes com espera progressiva e circuito; manter retomada após recuperação.

Critério de acompanhamento: Medir falhas por causa, idade do backlog, chamadas concluídas e tempo até retomada. Meta: conter ciclos sem perder eventos comerciais.

PRIORIDADE 1

Conferir gate/cache local e agrupar interações próximas

O código já exige interação nova após unfulfilled/inconclusive e possui fingerprint/cache. A publicação dessa regra não foi confirmada. Validar versão antes de atribuir benefício. Nos 7 dias, 870 reavaliações ocorreram em menos de 15 minutos da anterior.

Critério de acompanhamento: Medir chamadas e tokens por sugestão, proporção de evidência realmente nova, resultados cumpridos e alertas de prioridade/resposta preservados.

PRIORIDADE 1

Reduzir contexto automático e duplicação do WhatsApp

Rever a representação de atividades agent-skopos, mantendo ação, responsável, data, estado e prova. Enviar uma única cópia de additionalContext. Compactar scorecard e sugestões existentes preservando critérios e deduplicação.

Critério de acompanhamento: Medir tokens sem cache, cache, custo, recuperações e divergência semântica. Não remover todas as atividades nem assumir que caracteres equivalem a tokens.

PRIORIDADE 2

Pilotar contexto de risco e escolha de modelo

Risco: US$ 33,61 em 15 dias. O caminho compacto de reuniões e a seleção de evidências já existem como opções locais; ativação em produção não foi comprovada. Começar com empresa e amostra definidas; avaliar Luna versus Terra quando houver equivalência aceitável.

Critério de acompanhamento: Usar custo total por oportunidade, incluindo geração de fatos e segunda passagem. Modo shadow acrescenta chamadas e deve ter orçamento e término definidos.

MÉTODO E REFERÊNCIAS

Números reconciliados. Custo estimado, sem fatura.

Consulta de produção somente leitura; corte fixo em 13/10/2026 às 11h00, no fuso America/Sao_Paulo. Nenhum dado de negócio, runtime ou configuração de produção foi alterado.

Cobertura e reconciliação

Fonte principal: **ai_usage_events**, compartilhada pelo backend, consumers e crm-ai, enriquecida com **ai_agent_invocation_logs**. A chave de correspondência usa empresa e ID da invocação sem hífens. Nos 15 dias, 29.863 eventos têm log e 3.202 têm somente evento; não houve log com consumo fora dos eventos na amostra consolidada. As 29.863 correspondências não apresentaram divergência de contadores nem mudança de dia.

Total = entrada + saída. Cache já integra a entrada; raciocínio já integra a saída. Em 15 dias, entrada = 94,8% dos tokens; cache = 13,3% da entrada. As duas fontes podem perder registros quando a medição/persistência falha, e certos atendimentos/transcrições só geram eventos. O banco não comprova integralidade da fatura.

Tarifas usadas (USD por 1 milhão de tokens)

Modelo	Entrada	Cache	Saída
gpt-5.6-luna	0,20	0,02	1,20
gpt-5.6-terra	2,00	0,20	12,00
gpt-4.1-mini	0,40	0,10	1,60
gpt-4o-mini-transcribe	1,25	0,00	5,00
gpt-4o-transcribe-diarize	2,50	0,00	10,00

Estimativa = [(entrada - cache) × tarifa de entrada + cache × tarifa de cache + saída × tarifa de saída] / 1.000.000. Tarifas do banco foram aplicadas segundo sua vigência. Luna/Terra foram conferidas em páginas oficiais em 13/10. Duas transcrições segmentadas (30/09 e 01/10) não possuem usage: tokens e custo desconhecidos. Os totais em USD são a parte estimável, sem câmbio, impostos ou conciliação de fatura.

Referências para reprodução e implementação

SQL e relatório deste diagnóstico
crm-ai/docs/diagnostics/token-usage-2026-10-13/README.md

Gate de interação e cache existentes
crm-ai/docs/suggestion-verification-interactions.md

Seleção de evidências e recuperação
crm-ai/docs/verifier-evidence-selection.md

Compactação de reuniões em risco
crm-ai/docs/risk-meeting-context-rollout.md

Semântica do painel SaaS
BACKEND_CRM_SAAS/DOCS/saas-usage-analytics.md

OpenAI: gpt-5.6-luna | OpenAI: gpt-5.6-terra
Consultas encerradas; a auditoria confirmou zero outras conexões do diagnóstico. Créditos calculados (310.737 em 15 dias) não equivalem a USD; créditos debitados registrados no período = 0.